



林望舒

2022 级本科生 · 申请 2026 级博士研究生 · 高性能计算实验室

研究兴趣：机器学习系统 / 大模型推理优化 / 高效深度学习编译

☎ 138 0000 0000 ✉ wangshu.lin@example.com 🌐 wangshu.example.com 📁 github.com/example

RESEARCH CV

Systems × AI

PhD Application

🎓 教育背景

东南大学 · 计算机科学与技术 · 工学学士

2022.09 - 2026.06 (预计)

- 成绩排名: GPA 3.87 / 4.0, 专业排名 2 / 186; 核心课程: 机器学习、计算机体系结构、操作系统、编译原理、概率论与数理统计。
- 外语水平: CET-6 601, TOEFL 105 (Speaking 23); 能够熟练阅读英文文献并撰写英文论文。

南山大学 · 计算机科学 · 学期交换

2025.02 - 2025.06

- 修读《高级机器学习》《分布式系统》并均获 A; 参与系里公开组会与论文研读讨论。

🔬 科研经历

面向长上下文推理的 KV 缓存压缩 · 校级科研训练项目 (SRTP) 核心成员

2024.09 至今

指导教师: 周砚秋 教授 · 高性能计算实验室

41%

显存峰值降低

128K

单卡稳定上下文

12

评测数据集

MLSys 2026 Workshop

Under Review

- 问题与动机: 针对长上下文场景下 KV 缓存显存占用随序列长度增长的问题, 调研 PagedAttention、量化与稀疏化三条技术路线并形成综述报告。
- 方法与实现: 在 vLLM 推理框架上实现分块 KV 缓存与按需淘汰策略, 结合 token 重要性评分将显存峰值降低 41%, 支撑 128K 上下文在单卡 A100 上的稳定推理。
- 实验与验证: 设计覆盖 12 个数据集、3 类负载的评测流水线, 与 5 个基线方法对比吞吐与精度损失, 已投稿 MLSys 2026 Workshop (在审)。

大规模分布式训练加速 · 云启科技 AI 平台部 科研实习

2025.06 - 2025.09

- 个人工作: 参与千卡集群训练任务的性能剖析, 定位通信与计算重叠不足的瓶颈, 重构梯度同步路径并实现分桶重叠调度。
- 量化结果: 在 512 卡 BERT-Large 预训练任务上将端到端吞吐提升 18%, 相关优化合入内部训练框架并沉淀 2 篇技术文档。
- 协作方式: 与 SRE 团队共建故障注入与容错测试集, 完成 3 轮集群级演练报告, 训练中断恢复时间从分钟级降至秒级。
- 技术沉淀: 调研通信量化与稀疏梯度在混合精度训练中的适用边界, 输出内部技术评审报告并被采纳为后续迭代方向。

轻量级推理引擎内核优化 · 课程综合设计 (评分 A+, 全班前 3%)

2024.03 - 2024.06

- 基于 C++ / CUDA 实现算子融合与 Winograd 卷积优化, 在 ImageNet 子集上将 ResNet-50 推理延迟降低 27%。
- 编写完整的基准测试与数值一致性校验脚本, 代码以开源形式整理并附实验复现说明。

📄 论文与成果

- Wangshu Lin, Yanqiu Zhou, et al. "Block-wise KV Cache Compression for Long-context LLM Inference." *MLSys 2026 Workshop* 在审。
- 林望舒, 陈叙白. 《面向千卡集群的梯度同步分桶重叠调度方法》. 《东南大学学报 (自然科学版)》 已录用。
- Wangshu Lin, Xubai Chen. "Measuring Communication-Computation Overlap in Large-scale Training." 第一届学生系统研讨会海报 (2025)。

🔧 开源与学术服务

TorchKV · 开源 KV 缓存压缩工具库

2024.12 至今

- 发起并维护 (github.com/example/torchkv, 950+ star), 提供多种缓存淘汰与量化策略的可插拔实现, 附完整文档与复现实验。

《计算机体系结构》课程助教 · 东南大学

2025 秋季学期

- 负责实验课答疑与 RISC-V 流水线作业批改, 整理 3 份被后续学期沿用的实验讲义。

🏆 荣誉与奖项

- 国家奖学金 (2024, 全院 2 人)
- 校"优秀学生标兵" (2025)
- 全国大学生数学建模竞赛一等奖 (2024)
- 全国大学生系统与体系结构竞赛二等奖 (2025)
- 校一等奖学金 × 2 (2023, 2025)
- 东南大学"十佳本科生科研团队"成员 (2025)

🎯 未来研究设想

- 近期: 将 KV 缓存压缩工作扩展到投机解码与多模态推理场景, 系统刻画压缩率、精度与吞吐的权衡面, 形成完整的方法体系。
- 长期: 关注推理服务与编译协同优化的系统栈, 希望参与从算子、运行时到集群调度的一体化高效推理研究。

🔧 专业技能

- 系统与并行: 熟练使用 C++ / CUDA / Python / Rust, 了解 Triton; 熟悉 PyTorch、分布式训练 (DDP/TP/PP) 与 vLLM 推理栈。
- 工程与研究工具: 熟悉 Linux 开发环境、Slurm 集群调度、Git 协作与实验管理; 能独立完成文献调研、实验设计、论文写作与复现包整理。